

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN
KHOA CÔNG NGHỆ THÔNG TIN

----- oOo -----



BÀI TẬP THỰC HÀNH

XỬ LÝ DỮ LIỆU LỚN

TRÌNH ĐỘ: ĐẠI HỌC

NGÀNH ĐÀO TẠO: KHOA HỌC MÁY TÍNH

Hưng Yên – Tháng 02 năm 2023

BÀI THỰC HÀNH SỐ 4: XỬ LÝ DỮ LIỆU LỚN VỚI SPARK (1)

A. MỤC TIÊU BÀI THỰC HÀNH

Sau bài thực hành này sinh viên có thể:

- Cài đặt được chương trình Spark cho các bài toán thực tế
- Sử dụng thành thạo các hàm của Spark RDD và Spark DataFrame
- Chạy thử nghiệm được chương trình Spark trên hệ thống đã thiết lập

B. ĐIỀU KIỆN THỰC HÀNH

Với đặc thù của học phần Xử lý dữ liệu lớn, mục này sẽ liệt kê một số công cụ sử dụng để làm bài thực hành. Trong bài thực hành này, sinh viên cần kiểm tra và chắc chắn các phần mềm và phần cứng sau trên máy tính còn hoạt động tốt:

1. VirtuaBox phiên bản 6.0 trở lên
2. Ba máy ảo đã cài đặt hệ điều hành Ubuntu 20.04 trở lên
3. Máy tính cá nhân hoặc Laptop có cấu hình RAM $\geq 8\text{GB}$; Ổ cứng trống 50GB

C. TÀI NGUYÊN THAM CHIẾU

Để hoàn thành tốt bài thực hành này sinh viên nên tham khảo các tài nguyên sau:

STT	Tên tài nguyên	Mô tả tài nguyên
1	Bai tap thuc hanh 04.pdf	Tài liệu bài thực hành số 04
2	Bài giảng về Spark	Slide bài giảng về Spark

D. YÊU CẦU BÀI THỰC HÀNH

Bài 4.1.

Một hệ thống bán hàng gồm N cửa hàng bán lẻ (shop). Dữ liệu bán hàng của các shop được gửi về hệ thống máy chủ trung tâm để phân tích theo định kỳ. Dữ liệu của mỗi shop được lưu trữ trong 1 tệp *.csv (*Shop-k.csv*, $k \leq N$). Trong đó, mỗi dòng thể hiện tên các sản phẩm được mua trong mỗi hóa đơn của khách hàng, được ngăn cách bởi dấu phẩy (.). Ví dụ như bên dưới:

MILK,BREAD,BISCUIT
 BREAD,MILK,BISCUIT,CORNFLAKES
 BREAD,TEA,BOURNVITA
 JAM,MAGGI,BREAD,MILK
 MAGGI,TEA,BISCUIT
 BREAD,TEA,BOURNVITA

Giả sử lượng dữ liệu này là rất lớn. Bạn hãy viết chương trình sử dụng Spark RDD thống kê giúp chủ hệ thống:

- Số lượng mỗi sản phẩm bán được trong kỳ
- Top 10 sản phẩm bán chạy nhất trong kỳ (có số lượng kèm theo)

Bài 4.2. Thực hiện các thao tác cơ bản với Spark DataFrame sử dụng PySpark

- Tạo một Spark DataFrame **d** để lưu trữ dữ liệu thông tin chi tiết của các hóa đơn như sau:

OrderID	ProductID	ProductName	Quantity	Price	Discount
101	LAC	Acer Laptop	1	18900000	0.5
101	MLT	Logitech Mouse	2	300000	0.3
102	LAC	Acer Laptop	3	18900000	0.5
102	HPA	Panasonic Headphone	1	1000000	0.2
103	MMS	Microsoft Mouse	1	250000	0.6

- Hiển thị dữ liệu toàn bộ dữ liệu trong DataFrame ra màn hình
- Hiển thị dữ liệu các trường “OrderID, ProductID, ProductName” trong DataFrame ra màn hình
- Truy xuất lấy về dữ liệu của cột ProductID
- Truy xuất lấy về dữ liệu của một mã hóa đơn cụ thể
- Truy xuất lấy về các mặt hàng đã bán với chiết khấu ≥ 0.5 (50%)
- Tính tổng doanh thu trên toàn bộ sản phẩm bán được
- Tính tổng doanh thu trên mỗi sản phẩm, hiển thị ra màn hình với các trường như sau:
 ProductID, ProductName, Revenue (Doanh thu)

Bài 4.3. Sử dụng Spark DataFrame trong để phân tích dữ liệu của một Shop thời trang với 44,446 sản phẩm được lưu trữ trong các tệp **styles-01.csv** và **styles-02.csv** trên hệ thống phân tán Hadoop/HDFS tại thư mục **styles**.

a) Đọc toàn bộ dữ liệu trong tệp ra DataFrame và hiển thị ra màn hình

	id	gender	masterCategory	subCategory	articleType	baseColour	season	year	usage	productDisplayName
0	15970	Men	Apparel	Topwear	Shirts	Navy Blue	Fall	2011.0	Casual	Turtle Check Men Navy Blue Shirt
1	39386	Men	Apparel	Bottomwear	Jeans	Blue	Summer	2012.0	Casual	Peter England Men Party Blue Jeans
2	59263	Women	Accessories	Watches	Watches	Silver	Winter	2016.0	Casual	Titan Women Silver Watch
3	21379	Men	Apparel	Bottomwear	Track Pants	Black	Fall	2011.0	Casual	Manchester United Men Solid Black Track Pants
4	53759	Men	Apparel	Topwear	Tshirts	Grey	Summer	2012.0	Casual	Puma Men Grey T-shirt
...	...	...	...	...	...	...	...	...	...	...

b) Hiển thị ra các sản phẩm của năm 2019

c) Hiển thị ra các sản phẩm mùa “Winter” năm 2019

d) Hiển thị ra các sản phẩm áo “Tshirts” của “Men” năm 2019

e) Thống kê số lượng sản phẩm:

(1) Theo giới tính

(2) Theo năm

(3) Theo loại sản phẩm (articleType)

f) Thống kê số lượng các sản phẩm mỗi mùa của năm 2019 với 2 cột:

Season, Quantity

E. HƯỚNG DẪN THỰC HIỆN

Bài 4.1:

Sinh viên làm tương tự bài WordCount sử dụng RDD được giới thiệu trên lớp.

Bài 4.2:

Sinh viên làm tương tự làm theo ví dụ mẫu đã được giới thiệu trên lớp.

Bài 4.3:

Sinh viên làm tương tự làm theo ví dụ mẫu đã được giới thiệu trên lớp.

HẾT